

EEG2Image-JEPA: Geração de Imagens a partir de Sinais Cerebrais via Predição de Embeddings

Prof. Fabio Augusto M. Cappabianco

Aluno: Felipe Faustino Brito

Abstract—A tradução de sinais cerebrais em imagens é um desafio central na interface entre neurociência e inteligência artificial, dominado por modalidades de alto custo como a fMRI. Este trabalho investiga a viabilidade de uma *Joint-Embedding Predictive Architecture* (JEPA) como espinha dorsal de um decodificador de eletroencefalografia (EEG) para imagens. Propomos o EEG2Image-JEPA, que reformula a geração como *predição de embeddings*: um codificador de EEG e um preditor estimam o embedding CLIP de uma imagem-alvo, e um gerador pré-treinado e congelado (unCLIP) sintetiza a imagem, desacoplando a decodificação neural da síntese de pixels. Em avaliação *intra-sujeito* sobre uma sessão inédita do conjunto BCI IV-2a, o sistema decodifica a classe do sinal com 73,1% de acurácia (acaso de 33,3%) e a traduz em imagens nítidas e majoritariamente corretas, com erros neurofisiologicamente coerentes. Mais do que um sistema final, a principal contribuição é o mapeamento empírico dos *modos de falha* dessa abordagem: (i) colapso de representações, (ii) *posterior collapse* e (iii) regressão à média, e de suas mitigações (regularização anti-colapso, *dropout* de condicionamento e ancoragem *on-manifold*). Os resultados evidenciam que o teto de desempenho é imposto pela modalidade e não pela arquitetura.

Palavras-chave: EEG; interface cérebro-computador; JEPA; geração de imagens; modelos de difusão; aprendizado auto-supervisionado.

I. INTRODUÇÃO

A tradução da atividade cerebral em conteúdo visual interpretável é um dos desafios mais ambiciosos na fronteira entre neurociência e inteligência artificial [1]. Avanços em modelos generativos tornaram plausível evocar imagens a partir de sinais neurais, mas grande parte desse progresso apoia-se em fMRI ou eletrocorticografia modalidades de alto custo e baixa portabilidade [2]. A eletroencefalografia (EEG), não invasiva e barata, é a candidata natural para aplicações práticas, ao preço de uma razão sinal-ruído substancialmente menor.

As *Joint-Embedding Predictive Architectures* (JEPA), propostas por LeCun [3], oferecem um paradigma alternativo de aprendizado auto-supervisionado: em vez de reconstruir o sinal no espaço de entrada (e.g., pixels), uma JEPA prediz no espaço de representações. Um codificador mapeia a entrada para um embedding e um preditor estima o embedding de um alvo relacionado, favorecendo representações semânticas e evitando o custo de modelar detalhes de baixo nível. Notavelmente, a JEPA é descrita como não-generativa: ela captura dependências entre x e y sem sintetizar y diretamente [3]. Essa característica é particularmente atraente para o problema EEG-imagem: em vez de exigir que um sinal ruidoso gere pixels, a tarefa é reformulada como a *predição do embedding* da imagem-alvo, delegando a síntese a um gerador especializado.




Fig. 1. Arquitetura genérica de uma JEPA: as entradas x e y são processadas por codificadores que produzem as representações s_x e s_y ; um preditor estima s_y a partir de s_x , possivelmente condicionado a uma variável latente z .

Fonte: Assran [4].

Neste trabalho investigamos a viabilidade de uma arquitetura JEPA como espinha dorsal de um decodificador EEG-imagem. A motivação central é a própria arquitetura: examinar se o princípio de predição em espaço de embeddings, com seus mecanismos de anti-colapso, sustenta a tradução entre uma modalidade cerebral e uma visual. Propomos o **EEG2Image-JEPA**: um codificador de EEG produz um embedding do sinal; um preditor, condicionado a uma variável latente, estima o embedding de uma imagem-alvo da mesma classe; e um gerador pré-treinado e congelado sintetiza a imagem a partir do embedding predito.

Durante o desenvolvimento, a arquitetura revelou modos de falha característicos e instrutivos (colapso de representações, colapso do condicionador - *posterior collapse*), regressão à média na predição de embeddings e a inadequação de geradores treinados do zero sob escassez de dados. Diagnosticar e mitigar esses modos de falha é a contribuição central deste trabalho, pois são eles que delimitam o que é alcançável com a abordagem.

As principais contribuições são:

- **EEG2Image-JEPA**: modelo que reformula a geração de imagens a partir de EEG como predição de embeddings, desacoplando a decodificação neural da síntese de pixels.
- Diagnóstico empírico do colapso de representação, do *posterior collapse* e da regressão à média, com mitigações diretas.
- Avaliação *within-subject*, mostrando que a classe do sinal é decodável e capaz de dirigir a geração, e caracterizando o teto de desempenho imposto pelo EEG.

II. LACUNAS IDENTIFICADAS

A reconstrução de conteúdo visual a partir da atividade cerebral atingiu qualidade notável quando baseada em ressonância magnética funcional (fMRI) [5]. Tais abordagens, contudo, dependem de equipamentos caros e imóveis, inviáveis para uso prático e cotidiano. O EEG ocupa o extremo oposto sendo portátil e barato, mas sua baixa resolução espacial e alta razão ruído-sinal tornam a decodificação de experiências visuais um problema substancialmente mais difícil [6]. Persiste, assim, a lacuna de métodos que extraíam conteúdo visual de uma modalidade acessível como o EEG.

Os trabalhos pioneiros em EEG→imagem ilustram tanto o potencial quanto as limitações da área. O Brain2Image [1] combina LSTM com VAE e GAN para gerar imagens a partir de EEG, e o DreamDiffusion [6] acopla um codificador de EEG a um modelo de difusão pré-treinado. Apesar dos avanços, esses métodos compartilham dependências que ainda não foram plenamente endereçadas: a escassez de pares EEG–imagem limita o treinamento, e os resultados tendem a uma reconstrução apenas grosseira da *categoria* do estímulo, e não da imagem específica.

Uma segunda lacuna é metodológica. Avaliações em EEG–imagem frequentemente não isolam o que é, de fato, decodificável do sinal cerebral, nem caracterizam o teto de desempenho imposto pela própria modalidade. A distinção entre decodificar a *classe* de um estímulo e reconstruir seu *conteúdo* específico raramente é tornada explícita, o que dificulta interpretar honestamente o que um sistema aprendeu.

Por fim, há uma lacuna arquitetural. As *Joint-Embedding Predictive Architectures* foram propostas e validadas majoritariamente para aprendizado auto-supervisionado de representações de imagens e vídeo [4], e são, por construção, não-generativas [3]. O uso de uma JEPA como espinha dorsal de um pipeline *cross-modal* (EEG para imagem), acoplada a um gerador externo para a síntese, permanece pouco explorado. É precisamente essa combinação de predição em espaço de embeddings para decodificação neural e geração de imagens que este trabalho investiga, com ênfase nos modos de falha que ela acarreta.

III. TRABALHOS RELACIONADOS

A. Decodificação de Imagens a partir de Sinais Cerebrais

A reconstrução de estímulos visuais a partir da atividade cerebral consolidou-se primeiro sobre fMRI, com métodos que alcançam reconstruções de alta fidelidade ao alinhar padrões neurais a espaços semânticos e acoplá-los a modelos generativos [5]. No domínio do EEG, o Brain2Image [1] foi pioneiro ao combinar uma LSTM com VAE e GAN para sintetizar imagens de categorias do ImageNet a partir do sinal. Mais recentemente, o DreamDiffusion [6] obteve um salto de qualidade ao acoplar um codificador de EEG a um modelo de difusão pré-treinado, usando o codificador de imagens do CLIP como supervisão adicional para alinhar os embeddings de EEG e imagem sob a escassez de pares.

Este trabalho compartilha com o DreamDiffusion duas escolhas centrais: o uso de embeddings CLIP como alvo e de um gerador pré-treinado e congelado para a síntese.

Contudo, difere no objetivo e no enquadramento. Em vez de buscar máxima fidelidade por meio de *fine-tuning* extensivo, adotamos uma arquitetura JEPA explícita e a tratamos como objeto de estudo, caracterizando seus modos de falha e o teto de desempenho imposto pelo EEG.

B. Joint-Embedding Predictive Architectures

O paradigma JEPA foi proposto por LeCun [3] como alternativa às abordagens generativas e contrastivas: aprender prevendo no espaço de representações, e não no espaço de entrada. O I-JEPA [4] instanciou o conceito para imagens, prevendo representações de blocos mascarados a partir de um contexto, e validou empiricamente a tese de “prever no espaço latente”. Um desafio central das JEPAs é o *colapso de representações*, isso é, a solução trivial de mapear toda entrada a um ponto constante. O LeJEPA [7] aborda esse problema com fundamentação teórica: identifica a Gaussiana isotrópica como a distribuição-alvo ótima para os embeddings e introduz a *Sketched Isotropic Gaussian Regularization* (SIGReg), um regularizador que projeta os embeddings em direções aleatórias e força cada projeção a seguir uma Gaussiana padrão. Adotamos o SIGReg como mecanismo de anti-colapso no codificador de EEG do EEG2Image-JEPA.

C. Modelos para EEG e Geração Condicionada a Embeddings

No lado do EEG, o EEGNet [8] estabeleceu-se como uma arquitetura convolucional compacta e eficaz para BCIs, empregando convoluções *depthwise* e *separable* para extrair padrões espectrais e espaciais com poucos parâmetros. Por ser uma propriedade desejável sob dados escassos, utilizamos o EEGNet como codificador do sinal cerebral.

No lado da geração, o CLIP [9] forneceu um espaço de embeddings imagem-texto que se tornou um alvo semântico padrão para a síntese condicionada. Já O unCLIP [10] demonstrou a geração de imagens diretamente a partir de embeddings de imagem do CLIP, e os modelos de difusão latente [11] viabilizaram a síntese de alta qualidade a custo computacional reduzido, operando em um espaço latente compacto. Nosso pipeline emprega um gerador do tipo unCLIP, pré-treinado e congelado, para sintetizar a imagem final a partir do embedding CLIP predito pela JEPA.

IV. ESTADO DA ARTE

A. O pipeline dominante de cérebro-imagem

O estado da arte converge para um *template* recorrente: mapear o sinal neural para um espaço de embeddings semântico (tipicamente o CLIP [9]) e delegar a síntese a um gerador pré-treinado, como o unCLIP [10] ou a difusão latente [11]. Esse padrão sustenta tanto a reconstrução por fMRI [5] quanto os resultados em EEG [6]. Suas limitações são demarcadas: é faminto por dados, depende de *fine-tuning* extensivo, e em EEG a reconstrução tende a ser grosseira ao nível de *categoria*, não da imagem específica.

B. Decodificação de imagética motora

No EEG de imagética motora, o estado da arte é dominado por redes convolucionais compactas, como o EEGNet [8] e as redes de Schirrmeister et al. [12], refinadas por arquiteturas baseadas em *Transformers* [13]. O desempenho *intra-sujeito* no *benchmark* BCI Competition IV-2a permanece tipicamente em 70–85% para quatro classes, caindo sob avaliação *cross-subject*. Trata-se de um limite fundamental: o sinal carrega sobretudo a *classe* do movimento imaginado, e não a identidade de um estímulo visual.

C. JEPAs e a lacuna para a geração

As JEPAs evoluíram de heurísticas frágeis para formulações teoricamente fundamentadas, como o LeJEPa [7], que previne o colapso com um único regularizador (SIGReg). O paradigma já foi, inclusive, estendido a sinais cerebrais: o Brain-JEPa [14] é um modelo-fundação que aplica a JEPa à dinâmica cerebral medida por fMRI, alcançando estado da arte em predição demográfica e diagnóstico de doenças. Tais aplicações, contudo, restringem-se a tarefas *discriminativas* (classificação e regressão) sobre fMRI, e não à *geração* de imagens a partir de EEG. Persiste, assim, uma lacuna decisiva: a JEPa é, por construção, não-generativa [3], [4]. Acoplá-la a um gerador pré-treinado expõe uma limitação central: geradores como o unCLIP esperam embeddings *dentro de sua distribuição*, enquanto a predição por regressão tende a produzir o *embedding médio* da classe. Conciliar a predição de embeddings da JEPa com as exigências do gerador é o problema em aberto que a metodologia a seguir aborda.

V. METODOLOGIA DETALHADA

A. Formulação e Visão Geral

Reformulamos a geração de imagens a partir de EEG como *predição de embeddings* [3]. Um codificador mapeia o sinal x para $s_x = f_\theta(x)$; a imagem-alvo y é mapeada por um codificador CLIP congelado [?] para o alvo $s_y = h(y)$; um preditor p_ψ estima $\hat{s}_y$ a partir de s_x e de uma latente z ; e um gerador unCLIP congelado [?] sintetiza a imagem (Figura 2):

$$x f_\theta s_x p_\psi(\cdot, z) \hat{s}_y G \hat{y}.$$

A capacidade generativa reside no gerador pré-treinado; o aprendizado concentra-se em f_θ e p_ψ .

B. Codificador de EEG e Preditor

O codificador f_θ é uma rede compacta no estilo EEGNet [8], com convoluções temporal, *depthwise* (espacial) e *separable*. O preditor p_ψ é um MLP que recebe $[s_x; z]$ e produz $\hat{s}_y$, com dimensão igual à do embedding CLIP. Os alvos s_y são padronizados (*z-score*) por dimensão, evitando que o erro quadrático seja dominado pelas dimensões de maior variância.

C. Condicionador e Dropout de Condicionamento

Como o EEG determina apenas a *classe*, e não a imagem específica, um condicionador variacional q_ϕ modela a variação intra-classe, fornecendo z por reparametrização a partir de s_y . Para impedir que o preditor ignore s_x e dependa só de z (*posterior collapse*), aplicamos um *dropout* de condicionamento ao estilo *classifier-free*: no treino, z é substituído por ruído com probabilidade ρ , forçando o preditor a recuperar a classe a partir de s_x .

D. Objetivo de Treinamento

O treino minimiza

$$\mathcal{L} = \hat{s}_y - s_{y2}^2 + \lambda \mathcal{R}_{SIG}(s_x) + \beta D_{KL}(q_\phi(z | s_y) \| \mathcal{N}(0, I)),$$

combinando a predição do embedding, a *Sketched Isotropic Gaussian Regularization* (SIGReg) [7] contra o colapso de representações, e o termo do condicionador. A SIGReg é aplicada apenas a s_x : o alvo s_y é congelado e não pode colapsar.

E. Geração On-Manifold

A predição por erro quadrático converge para o embedding *médio* da classe, que cai fora da variedade dos embeddings CLIP reais e leva o gerador a produzir artefatos. Ancoramos, então, $\hat{s}_y$ na variedade antes da síntese, recuperando o embedding real mais próximo em uma galeria $\mathcal{G}$ de embeddings de treino, e fornecendo-o ao gerador. A recuperação usa o embedding predito completo (não um rótulo), e o gerador sintetiza uma imagem nova a partir dele.

VI. MATERIAIS E MÉTODOS PROPOSTOS

A. Dataset e Pré-processamento

Utilizamos o BCI Competition IV-2a (BNCI2014-001) [15], acessado via MOABB [16], que contém EEG de imagética motora de nove sujeitos em 22 canais, gravado em *duas sessões* em dias distintos. Adotamos um cenário *intra-sujeito* (sujeito 1) e três das quatro classes (mão direita, pés, língua). Os sinais foram filtrados em 4–40 Hz e reamostrados para 128 Hz, e cada trecho foi normalizado por *z-score* por canal. Cada trial resulta em um tensor de 22×513 amostras.

A divisão treino/validação é feita *por sessão*: a primeira sessão (216 trials, 72 por classe) é usada para treino, e a segunda (216 trials) para validação. Como as sessões foram gravadas em dias diferentes, a validação avalia a generalização a sinais genuinamente inéditos.

B. Imagens-alvo

Para cada uma das três classes (mão, pé e língua) reunimos 55 imagens-alvo, geradas sinteticamente com o modelo Stable Diffusion por meio da interface *stable-diffusion-webui* [17]. Por conforto e melhor identificação visual, a classe “língua” foi representada por imagens de *caneta*. As imagens são redimensionadas para 64×64 , e 5 por classe são reservadas para teste do gerador. Cada imagem é convertida em um embedding CLIP fixo, formando os alvos s_y e a galeria $\mathcal{G}$ usada na geração *on-manifold*. Durante o treino, cada trial de EEG é pareado a um embedding aleatório de uma imagem da sua classe, fornecendo diversidade intra-classe.




Fig. 2. Visão geral do EEG2Image-JEPA. Em azul, os módulos treináveis (f_θ , p_ψ , q_ϕ); em cinza, os módulos congelados (codificador CLIP e gerador unCLIP).

C. Configuração do Modelo e Treinamento

O codificador de EEG produz $s_x \in R^{128}$, a latente de condicionamento tem dimensão 16, e o preditor produz embeddings de dimensão 768, compatível com o codificador CLIP (ViT-L) do gerador unCLIP empregado (*stable-diffusion-2-1-unclip*). Os pesos da função-objetivo são $\lambda = 0,1$ (SIGReg) e $\beta = 10^{-3}$ (KL), e o *dropout* de condicionamento usa $\rho = 0,5$. O treino emprega o otimizador AdamW (taxa de aprendizado 3×10^{-4} , *weight decay* 10^{-4}) com agendamento por cosseno, *clipping* de gradiente e 300 épocas. Codificador CLIP e gerador permanecem congelados.

D. Protocolo de Avaliação

Avaliamos o sistema em dois eixos. Primeiro, a *decodificação de classe*: treina-se uma sonda linear (regressão logística) sobre os embeddings preditos $\hat{s}_y$ do treino e mede-se a acurácia na validação, reportando também a matriz de confusão por classe. Esse eixo isola o que é efetivamente decodificável do sinal cerebral, independentemente da síntese. Segundo, a *geração*: a partir do EEG de validação, sintetizam-se imagens via ancoragem *on-manifold* e gerador unCLIP, inspecionadas qualitativamente por classe. Como linha de base, todas as métricas são comparadas ao acaso ($1/3$).




Fig. 3. Matriz de confusão na validação (sessão inédita). Linhas: classe real do EEG; colunas: classe predita.

VII. RESULTADOS EXPERIMENTAIS E AVALIAÇÃO

A. Decodificação de Classe

A sonda linear sobre os embeddings preditos $\hat{s}_y$ alcança 73,1% de acurácia na sessão de validação (inédita), contra 33,3% do acaso, evidenciando que o sinal de EEG é decodificável e que o preditor preserva essa informação no espaço CLIP. A matriz de confusão (Figura 3) revela um padrão neurofisiologicamente coerente: a classe *mão direita* é quase perfeitamente separada (0,96), enquanto os erros concentram-se entre *pé* (0,60) e *língua* (0,64), cujas representações sensorio-motoras são adjacentes no córtex. O teto de desempenho é, portanto, imposto pela modalidade, e não pela arquitetura.

B. Geração de Imagens

A Figura 4 mostra, para trials de validação, o sinal de EEG de entrada (canais C3, Cz, C4) e a imagem sintetizada pelo *pipeline* completo. As imagens são *nítidas* e majoritariamente da classe correta, com os erros recaindo, como esperado, na confusão *pé* $\leftrightarrow$ *língua*. Note-se que, embora os traçados de EEG das três classes sejam visualmente similares, o sistema recupera a classe e a traduz em uma imagem coerente.




Fig. 4. EEG de validação (entrada) e imagem gerada (saída) por trial. Cada coluna é um trial inédito; o título indica a classe gerada (acerto/erro).

C. Modos de Falha

O caráter do estudo permitiu caracterizar empiricamente os modos de falha da abordagem. Observamos (i) *colapso de representações* na ausência de regularização anti-colapso; (ii) *posterior collapse*, em que o preditor ignora s_x e depende apenas de z , mitigado pelo *dropout* de condicionamento; e (iii) a *regressão à média*, em que o embedding predito por ser a média da classe cai fora da variedade do gerador, produzindo artefatos.

VIII. CONCLUSÕES E IMPACTO CIENTÍFICO

Este trabalho investigou a viabilidade de uma arquitetura JEPA como alicerce de um decodificador EEG-imagem. O EEG2Image-JEPA reformula a tarefa como predição de embeddings, desacoplando a decodificação neural da síntese de pixels por meio de um gerador pré-treinado e congelado. Em avaliação *intra-sujeito* sobre sessão inédita, o sistema decodificou a classe do sinal com 73,1% de acurácia e a traduziu em imagens nítidas e majoritariamente corretas, com erros neurofisiologicamente coerentes (confusão entre *pé* e *língua*).

A contribuição central, contudo, é o *mapeamento dos modos de falha* dessa classe de arquiteturas: o colapso de representações, o *posterior collapse* e, sobretudo, a regressão à média. Para cada um, identificamos mitigações diretas (SIGReg, *dropout* de condicionamento e ancoragem *on-manifold*). Mostramos, ainda, que sob escassez de dados o poder generativo deve ser *importado* de um modelo pré-treinado, e não aprendido do zero.

A. Limitações

Os resultados devem ser lidos à luz de suas limitações. A avaliação restringe-se a um sujeito e três classes; o desempenho *cross-subject* tende a ser inferior. O teto de qualidade é imposto pela modalidade: o EEG de imagética motora carrega a *classe* do movimento imaginado, não a identidade de um estímulo visual, de modo que o sistema gera uma imagem *associada à classe*, e não uma reconstrução perceptual. As imagens-alvo são sintéticas e a associação entre classe e conceito visual é arbitrária (a classe “língua” foi representada por canetas), reforçando que se trata de decodificação de classe seguida de síntese, e não de leitura de conteúdo visual do cérebro. Por fim, a ancoragem *on-manifold* é uma escolha pragmática sob poucos dados; uma solução plenamente generativa exigiria um *prior* de difusão no espaço de embeddings, inviável na escala de dados disponível.

B. Trabalhos Futuros

Direções naturais incluem a varredura dos nove sujeitos do *benchmark* e a avaliação *cross-subject*; a ampliação do conjunto de imagens-alvo; a substituição da ancoragem por um *prior* generativo no espaço CLIP, à medida que mais pares estejam disponíveis; e a adoção de regularizadores anti-colapso mais recentes. O EEG2Image-JEPA posiciona-se, assim, menos como um produto final e mais como um estudo metodológico honesto sobre o que arquiteturas preditivas de embeddings podem (e não podem) alcançar na decodificação visual a partir de EEG.

REFERENCES

- [1] I. Kavasidis, S. Palazzo, C. Spampinato, D. Giordano, and M. Shah, “Brain2Image: Converting brain signals into images,” in *Proceedings of the 25th ACM international conference on Multimedia*, 2017, pp. 1809–1817.
- [2] Z. Chen, J. Qing, T. Xiang, W. L. Yue, and J. H. Zhou, “Seeing beyond the brain: Conditional diffusion model with sparse masked modeling for vision decoding,” in *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, 2023, pp. 22 710–22 720.
- [3] Y. LeCun *et al.*, “A path towards autonomous machine intelligence version 0.9. 2, 2022-06-27,” *Open Review*, vol. 62, no. 1, pp. 1–62, 2022.
- [4] M. Assran, Q. Duval, I. Misra, P. Bojanowski, P. Vincent, M. Rabbat, Y. LeCun, and N. Ballas, “Self-supervised learning from images with a joint-embedding predictive architecture,” in *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, 2023, pp. 15 619–15 629.
- [5] P. S. Scotti, A. Banerjee, J. Goode, S. Shabalin, A. Nguyen, E. Cohen, A. J. Dempster, N. Verlinde, E. Yundler, D. Weisberg *et al.*, “Reconstructing the mind’s eye: fmri-to-image with contrastive learning and diffusion priors (2023),” *arXiv preprint arxiv:2305.18274*.
- [6] Y. Bai, X. Wang, Y.-P. Cao, Y. Ge, C. Yuan, and Y. Shan, “Dreamdiffusion: High-quality eeg-to-image generation with temporal masked signal modeling and clip alignment,” in *European Conference on Computer Vision*. Springer, 2024, pp. 472–488.
- [7] R. Balestrierio and Y. LeCun, “Lejepa: Provable and scalable self-supervised learning without the heuristics, 2025,” URL <https://arxiv.org/abs/2511.08544>, vol. 10.
- [8] V. J. Lawhern, A. J. Solon, N. R. Waytowich, S. M. Gordon, C. P. Hung, and B. J. Lance, “Eegnet: a compact convolutional neural network for eeg-based brain–computer interfaces,” *Journal of neural engineering*, vol. 15, no. 5, p. 056013, 2018.
- [9] A. Radford, J. W. Kim, C. Hallacy, A. Ramesh, G. Goh, S. Agarwal, G. Sastry, A. Askell, P. Mishkin, J. Clark *et al.*, “Learning transferable visual models from natural language supervision,” in *International conference on machine learning*. PmlR, 2021, pp. 8748–8763.
- [10] A. Ramesh, P. Dhariwal, A. Nichol, C. Chu, and M. Chen, “Hierarchical text-conditional image generation with clip latents,” *arXiv preprint arXiv:2204.06125*, vol. 1, no. 2, p. 3, 2022.
- [11] R. Rombach, A. Blattmann, D. Lorenz, P. Esser, and B. Ommer, “High-resolution image synthesis with latent diffusion models,” in *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, 2022, pp. 10 684–10 695.
- [12] R. T. Schirmermeister, J. T. Springenberg, L. D. J. Fiederer, M. Glasstetter, K. Eggensperger, M. Tangemann, F. Hutter, W. Burgard, and T. Ball, “Deep learning with convolutional neural networks for eeg decoding and visualization,” *Human brain mapping*, vol. 38, no. 11, pp. 5391–5420, 2017.
- [13] Y. Song, Q. Zheng, B. Liu, and X. Gao, “Eeg conformer: Convolutional transformer for eeg decoding and visualization,” *IEEE Transactions on Neural Systems and Rehabilitation Engineering*, vol. 31, pp. 710–719, 2022.
- [14] Z. Dong, R. Li, Y. Wu, T. T. Nguyen, J. S. Chong, F. Ji, N. R. Tong, C. L. Chen, and J. H. Zhou, “Brain-jepa: Brain dynamics foundation model with gradient positioning and spatiotemporal masking,” *Advances in Neural Information Processing Systems*, vol. 37, pp. 86 048–86 073, 2024.
- [15] M. Tangemann, K.-R. Müller, A. Aertsen, N. Birbaumer, C. Braun, C. Brunner, R. Leeb, C. Mehring, K. J. Miller, G. R. Müller-Putz *et al.*, “Review of the bci competition iv,” *Frontiers in neuroscience*, vol. 6, p. 55, 2012.
- [16] B. Aristimunya, I. Carrara, P. Guetschel, S. Sedlar, P. Rodrigues, J. Sosulski, D. Narayanan, E. Bjareholt, Q. Barthelemy, R. T. Schirmermeister, R. Kobler, E. Kalunga, L. Darmet, C. Gregoire, A. Abdul Hussain, R. Gatti, V. Goncharenko, A. Andreev, A. Tates, S. Kojima, J. Thielen, D. Hajhassani, K. Begany, T. Moreau, Y. Roy, V. Jayaram, A. Barachant, and S. Chevallier, “Mother of all bci benchmarks,” 2026. [Online]. Available: <https://github.com/NeuroTechX/maobb>
- [17] AUTOMATIC1111, “Stable diffusion web ui,” <https://github.com/AUTOMATIC1111/stable-diffusion-webui>, 2022, acesso em: 30 jun. 2026.